

WENXIN MOYUN × VULCA

文化语境任务中多模态模型的评估、引导与可视化

Haorui Yu · Ramon Ruiz-Dolz · Qiufeng Yi

EMNLP 2025 Findings · University of Dundee / Birmingham

42 模型 · 15 机构

28 真实上线 · 64 条 E2E

Cloud Run 生产 · 15m CI/CD

01. 现状与挑战

多模态模型（GPT-4o、LLaVA 等）在高语境文化任务仍易“表层复述、缺乏意境”。

- 中国画评论：难捕捉 **意境 (Yijing)** 与 **气韵 (Qiyun)**。
- 象征性推理不足，易丢失文化隐喻与历史脉络。
- Benchmark 多聚焦事实问答，**认知对齐** 缺位。

“表层正确 ≠ 文化对齐；需要可解释的引导与量化评估。”

02. 数据与生产基线

以 郎世宁《十二月令》专家评论构建 MHEB，支撑 VULCA 评估；文心墨韵平台提供实时演示与对战。

163

专家评论

38

特征标签

5

文化维度

03. 角色引导 (8 PERSONAS)

以文化视角构建 8 个批评者角色，结合知识库 Prompt，迫使模型进入特定认知框架。

苏轼 · Su Shi

郭熙 · Guo Xi

John Ruskin

冈仓天心 · Okakura Kakuzō

Dr. Aris Thorne

Mama Zola

Professor Elena Petrova

Brother Thomas

机制：Persona Prompt + JSON 知识库 → 减少幻觉，提升深度与文化贴合度。

04. 联合评测管线

语义向量嵌入：

05. 文化理解可视化 (论文表 1 & 表 4)

Top 5 组合 (表 1)：Composite / Expert Alignment

Qwen2.5-VL-7B + Mama Zola + KB 9.2 / 100%

Llama-4-Scout-17B + John Ruskin + KB 8.9 / 97%

Llama-4-Scout-17B + Mama Zola + KB 8.7 / 95%

Llama-4-Scout-17B + Brother Thomas + KB 8.5 / 92%

Llama-4-Scout-17B + Su Shi + KB 8.5 / 92%

关键维度 (表 4 示例)：艺术意境 0.891 vs 0.851；笔墨技法 0.937 vs 0.903；章法布局 0.895 vs 0.916 (Qwen2.5-VL / Llama-4-Scout)。

07. 关键提升

Qwen2.5-VL-7B + Mama Zola Composite 9.2 / Align 100%

Llama-4-Scout + John Ruskin Composite 8.9 / Align 97%

Llama-4-Scout + Mama Zola Composite 8.7 / Align 95%

数据来源：2025.findings-emnlp.103.pdf 表 1 (Top 5 配置) 与表 4 (维度得分)。

08. 技术剖析

- 前端：React19 + Tailwind，文本高亮/智能切块，HashRouter 导航修复，缓存版本 v2.1.0。
- 后端：FastAPI + SQLAlchemy，统一模型接口；任务队列 + WebSocket 推送对战进度。
- 嵌入/向量分析：BAAI/bge-large-zh-v1.5 (1024d)；质心距离 + 余弦相似度 + EMD；kmeans=5 聚类。

42支持模型

28真实模型上线

64E2E用例

前端 React 19 + Tailwind

后端 FastAPI + SQLAlchemy

统一模型接口 + WebSocket

Cloud Run + Cloud SQL

Model: BAAI/bge-large-zh-v1.5 · 1024-d

质心距离 (Centroid Distance):

$$C_p = (1 / |D_p|) \cdot \sum x_d$$

计算模型输出与专家群体的向量距离，越近代表文化对齐度越高；结合余弦相似度、EMD 与画像质心对齐 (kmeans=5)。

生产就绪:

- 统一模型接口 + 队列: OpenAI / Anthropic / DeepSeek / Qwen。
- 前端高亮 + 智能切块, HashRouter 修复, 缓存版本 v2.1.0。
- CI/CD 15m, Cloud Run + Cloud Storage + Cloud SQL; WebSocket 对战推送。

06. 关键维度对比 (论文表 4)

来源: 2025.findings-emnlp.103.pdf
表 4 (示例三维) · Qwen2.5-VL vs Llama-4-Scout

艺术意境 (Artistic Conception) 0.891

艺术意境 · Llama-4 0.851

笔墨技法 (Brushwork) 0.937

笔墨技法 · Llama-4 0.903

章法布局 (Layout) 0.895

章法布局 · Llama-4 0.916

表 4 关键示例: Qwen 在意境/笔墨领先, Llama-4 在布局略高; 均为干预配置下的维度得分。

- 数据: MHEB 163 评论 × 38 特征 × 5 文化维度; 28 真实模型生产数据。
- 评测: OpenAI 基准 (11 模型 × 6 用例, GPT-4o-mini 87.2) ; VULCA 雷达 (Qwen2.5-VL 领先)。
- 部署: GCP Cloud Run / Cloud SQL / Cloud Storage; CI/CD 15 分钟; 64 E2E 守护。

Persona Prompt + KB

多阶段评测管线

雷达 + 条形图可视化

真实对战 + 投票

09. 结论与下一步

- 文化适应性 需要 Persona + 知识库 + 语义质心联合约束。
- 文心墨韵提供真实生产链路: 模型对战、评分可视化、64 E2E 守护质量。
- 可泛化领域: 宗教文本、医学叙事、历史评论、设计批评。

Demo & Code

前端 <http://localhost:5173> · 后端 <http://localhost:8001> · [demo/demo123](#)
更多: 2025.findings-emnlp.103.pdf · [openai_benchmark_v2_report.md](#)

